

به نام خدا



Fuzzy methods and systems

Assignment number 5

Masoud Fatemi

Distributed representation of fuzzy rules and its application to  
pattern classification


## مقدمه

هدف ما در این جا کلاس بندی الگوها در یک فضای ۲ بعدی به ۲ کلاس مختلف با استفاده از قوانین فازی می باشد. برای این منظور با استفاده از داده های آموزش که به الگوریتم داده می شوند قوانین فازی برای کلاس بندی استخراج می شوند. سپس در مرحله بعد داده های تست را با استفاده از قوانین فازی که در مرحله قبل ساخته ایم در ۲ کلاس مختلف کلاس بندی می کنیم و دقت الگوریتم را نیز محاسبه می کنیم.

در ابتدا روشی که توسط مقاله ارائه شده به صورت مختصر شرح داده می شود و سپس به صورت دقیق و مرحله به مرحله مراحل انجام کار همراه با پیاده سازی صورت گرفته شرح داده می شوند.

## روش ارائه شده توسط مقاله

در این مقاله در ابتدا فرض می کنیم ما تعدادی داده ی آموزش به صورت  $x_p = (x_{1p}, x_{2p})$  که هر کدام عضو کلاس  $G_1$  یا  $G_2$  هستند داریم. این داده ها در فضایی ۲ بعدی که ابعاد آن را  $[0,1] \times [0,1]$  در نظر می گیریم توزیع شده اند. حال فرض می کنیم که هر بعد فضای مورد نظر را به  $L$  قسمت کوچکتر تقسیم می کنیم که در این صورت برای  $L=2$  شکلی مانند شکل زیر به دست می آوریم که به آن rule table متناظر با  $L=2$  گفته می شود.



ما برای  $L=2$  چهار ناحیه به دست می آوریم که برای آنها قوانین فازی را به صورت زیر می نویسیم:

If  $x_1$  is  $A_i^L$  and  $x_2$  is  $A_j^L$  then ...  $i, j = 1, 2, \dots, L$ .

در روش پیشنهادی در این مقاله فرض شده است که به صورت هم زمان از  $L-1$  rule table برای کلاس بندی استفاده می کنیم که قوانین آن به صورت زیر نوشته می شوند:

If  $x_1$  is  $A_i^L$  and  $x_2$  is  $A_j^L$  then ...  $i, j = 1, 2, \dots, K$ ;  $K = 2, 3, \dots, L$ .

حال اگر فرض کنیم که هر محور فضای الگوهای ما به  $K$  قسمت تقسیم شده است برای هر قسمت یک membership function مثلثی یا دوزنقه با توجه با فرمول‌های زیر در نظر می‌گیریم که به  $K$  و  $i$  وابسته می‌باشند. سپس معیاری به نام CF معرفی می‌شود که درجه اطمینان ما از اینکه هر داده به کدام کلاس  $G1$  یا  $G2$  تعلق دارد را بیان می‌کند

$$\mu_i^K(x) = \max \{ 1 - |x - a_i^K|/b^K, 0 \} \quad i = 1, 2, \dots, K$$

$$\mu_i^K(x) = \max \{ \min \{ 2 - 2|x - a_i^K|/b^K, 1 \}, 0 \} \quad i = 1, 2, \dots, K$$

$$a_i^K = (i - 1)/(K - 1) \quad i = 1, 2, \dots, K$$

$$b^K = 1/(K - 1)$$

در نهایت قوانین فازی به صورت زیر نوشته می‌شوند که با استفاده از تمام داده‌های آموزش به دست می‌آیند:

If  $x_{1p}$  is  $A_i^L$  and  $x_{2p}$  is  $A_j^L$  then then  $x_p$  belongs to  $G_{ij}^K$  with  $CF = CF_{ij}^K$

مراحل استخراج قوانین فازی از داده‌های آموزش بر اساس روش پیشنهادی مقاله به صورت زیر می‌باشد:  
(۱) از  $K=2$  تا یک  $L$  ماکسیمم برای هر  $K$  فضای الگوها را به  $K$  قسمت تقسیم می‌کنیم و در هر مرحله برای تمام داده‌های کلاس  $G1$  و برای تمام داده‌های کلاس  $G2$  میزان عضویت یا درجه ی تعلق به توابع عضویت متناظر با هر قسمت را حساب کرده و مقدار  $\beta$  متناظر را بر اساس فرمول زیر که آن را به عنوان سازگاری تعریف می‌کنیم به دست می‌آوریم.

$$\beta_{G1} = \sum_{p \in G1} \mu_i^K(x_{1p}) \cdot \mu_j^K(x_{2p})$$

$$\beta_{G2} = \sum_{p \in G2} \mu_i^K(x_{1p}) \cdot \mu_j^K(x_{2p})$$

(۲) اگر برای یک ناحیه  $\beta_{G1} = \beta_{G2}$  باشد ما برای آن ناحیه هیچ قانونی نمی‌سازیم ولی اگر بین مقادیر  $\beta$  محاسبه شده برای کلاس  $G1$  و  $G2$  برای یک ناحیه فازی اختلاف وجود داشته باشد از شرایط زیر برای تعیین کلاس در قسمت متناظر استفاده می‌کنیم:

$$\beta_{G1} > \beta_{G2} \text{ then } G_{ij}^K = G1$$

$$\beta_{G1} < \beta_{G2} \text{ then } G_{ij}^K = G2$$

(۳) برای هر قسمت با توجه با مقادیر سازگاری حساب شده مقدار CF را بر اساس فرمول زیر محاسبه می‌کنیم:

$$CF_{ij}^K = |\beta_{G1} - \beta_{G2}| / (\beta_{G1} + \beta_{G2})$$

در محاسبه مقادیر  $\beta$  برای هر ناحیه می توان به جای استفاده از t-norm ضرب بین درجه های عضویت از t-norm مینیمم استفاده کرد که در این صورت فرمول های محاسبه مقادیر سازگاری به صورت زیر می شوند:

$$\beta_{G1} = \sum_{p \in G1} \mu_i^K(x_{1p}) \wedge \mu_j^K(x_{2p})$$

$$\beta_{G2} = \sum_{p \in G2} \mu_i^K(x_{1p}) \wedge \mu_j^K(x_{2p})$$

با جایگزینی  $K=2,3,\dots,L$  بر اساس مراحل که در بالا ذکر شده قوانین فازی را به شکل زیر از داهای عددی به دست می آوریم که از آنها برای کلاس بندی داده های تست و یا یک داده ی ناشناخته استفاده می کنیم.

If  $x_{1p}$  is  $A_i^L$  and  $x_{2p}$  is  $A_j^L$  then then  $x_p$  belongs to  $G_{ij}^K$  with  $CF = CF_{ij}^K$   $i, j = 1, 2, \dots, K ; K = 2, 3, \dots, L$

مراحل به دست آوردن کلاس برای یک داده ی جدید ناشناخته و یا داده های تست به صورت زیر می باشد:  
(۱) محاسبه مقادیر  $\alpha_{G1}$  و  $\alpha_{G2}$  براساس فرمول زیر:

$$\alpha_{G1} = \max \{ \mu_i^K(x_{1p}) \cdot \mu_j^K(x_{2p}) \cdot CF_{ij}^K | G_{ij}^K = G1 ; i, j = 1, 2, \dots, K ; K = 2, 3, \dots, L \}$$

$$\alpha_{G2} = \max \{ \mu_i^K(x_{1p}) \cdot \mu_j^K(x_{2p}) \cdot CF_{ij}^K | G_{ij}^K = G2 ; i, j = 1, 2, \dots, K ; K = 2, 3, \dots, L \}$$

(۲) اگر  $\alpha_{G1} > \alpha_{G2}$  نتیجه می گیریم که داده ی مورد نظر به کلاس  $G1$  تعلق دارد با درجه ی حمایت یا اطمینان  $\alpha_{G1} - \alpha_{G2}$  ولی اگر  $\alpha_{G2} > \alpha_{G1}$  بود نتیجه می گیریم که داده ی مورد نظر به کلاس  $G2$  تعلق دارد با درجه ی حمایت  $\alpha_{G2} - \alpha_{G1}$ .

اگر در محاسبه ی مقادیر سازگاری از t-norm مینیمم استفاده شود در این صورت برای محاسبه مقادیر  $\alpha_{G1}$  و  $\alpha_{G2}$  از فرمول زیر استفاده می کنیم:

$$\alpha_{G1} = \max \{ [\mu_i^K(x_{1p}) \wedge \mu_j^K(x_{2p})] \cdot CF_{ij}^K | G_{ij}^K = G1 ; i, j = 1, 2, \dots, K ; K = 2, 3, \dots, L \}$$

$$\alpha_{G2} = \max \{ [\mu_i^K(x_{1p}) \wedge \mu_j^K(x_{2p})] \cdot CF_{ij}^K | G_{ij}^K = G2 ; i, j = 1, 2, \dots, K ; K = 2, 3, \dots, L \}$$

انتظار می رود که با افزایش مقدار  $L$  دقت الگوریتم برای کلاس بندی داده های تست بیشتر شود. اما بر اساس شبیه سازی های کامپوتری انجام شده مشاهده می شود که در روش پیشنهادی توسط مقاله افزایش مقدار  $L$  تاثیری در قدرت الگوریتم نخواهد داشت.

## پیاده سازی:

روش پیشنهادی توسط مقاله که در بالا به صورت خلاصه توضیح داده شد در محیط متلب پیاده سازی شده است و فایل آن همراه این گزارش ارسال شده است. در این بخش به صورت مرحله به مرحله روش پیشنهاد شده

همراه با پیاده سازی مربوطه شرح داده می شود. پیاده سازی صورت گرفته شامل قسمت‌های زیر می‌باشد که در متن کد نوشته شده هم با همین عناوین با کامنت مشخص شده اند.

### Generate Train Data

در این قسمت ما داده‌های آموزش خود را ساخته تا با استفاده از آنها قوانین فازی مورد نیاز برای کلاس بندی را تولید کنیم. یک ماتریس با ۴۰ سطر و ۲ ستون شامل اعداد تصادفی بین ۰ تا ۱ می سازیم و سپس ستون اول این ماتریس را در متغیر  $x1$  و ستون دوم آن را در متغیر  $x2$  میریزیم. بعد از آن با استفاده از `problem 1` که توسط مقاله تعریف شده است مقدار خروجی را به ازای هر داده ی ورودی  $x$  که شامل ۲ مقدار  $x1$  و  $x2$  است محاسبه کرده و در متغیر `problem_number_one_value` قرار می دهیم. بعد از آن برای تمام مقادیر محاسبه شده به آنهایی که مثبت هستند کلاس ۱ و به آنهایی که منفی هستند کلاس ۲ را نسبت می دهیم. تا به اینجا ما ۴۰ داده ی دو بعدی در فضای  $[0,1] \times [0,1]$  تولید کرده ایم که هر کدام از آنها یا در کلاس ۱ یا در کلاس ۲ قرار دارند.

### Plot Train Data

در این قسمت ما داده‌های تولید شده در مرحله ی قبل را جهت پیدا کردن دیدی مناسب و درکی بهتر از موضوع در یک فضای ۲ بعدی ترسیم نموده. وجود این بخش اختیاری می‌باشد و تاثیری در پاسخ نهایی ندارد.

### Variables Definition

در این بخش متغیرها و پارامترهای مورد نیاز در ادامه ی الگوریتم تعریف می شوند، در سطر اول این بخش ماتریس داده‌های آموزش که شامل داده‌های ۲ بعدی و کلاس آنها می‌باشد تولید می شود. همچنین ۲ متغیر  $g1$  و  $g2$  که در انتهای این بخش تعریف شده اند شامل داده‌های کلاس  $g1$  و داده‌های کلاس  $g2$  به صورت جداگانه می باشند. در انتهای این قسمت با توجه به این نکته که در مقاله ذکر شده است که افزایش مقدار  $L$  تاثیری در قدرت روش کلاس بندی پیشنهادی ندارد لذا در اینجا نیز مانند مقاله میزان ماکسیمم برای  $L$  برابر ۲۰ در نظر گرفته می شود.

### Create Fuzzy Rules

این بخش از ۳ حلقه ی تکرار تو در تو جهت تولید قوانین فازی استفاده می کند. حلقه ی بیرونی مقدار  $K$  که برابر تعداد بخش‌های فضای الگویی در هر مرحله می‌باشد را تا رسیدن به مقدار ماکسیمم می شمارد و دو حلقه دیگر تمام قسمت بندی‌های هر مرحله را برای تولید قوانین فازی جستجو می کنند.  $q$  اندیس شمارشگر تعداد قوانین تولید شده می‌باشد که در ابتدای حلقه سوم قرار گرفته و به ازای تولید هر قانون یکی اضافه می شود.  $beta\_class\_g1$  و  $beta\_class\_g2$  همان مقادیر سازگاری می باشند که با توجه به فرمول ارائه شده در

مقاله محاسبه می‌شوند. روش محاسبه مقادیر سازگاری به این صورت است که به ازای هر  $K$  و  $i$  برای تمام داده‌های کلاس ۱ میزان تعلق آنها در هر دو بعد به membership functionهای مثلثی (یا دوزنقه ای) متناظر با هر قسمت جداگانه حساب شده و سپس برای هر داده این مقادیر در هم ضرب شده و با مقادیر دیگر داده‌ها جمع شده و به عنوان مقدار سازگاری کلاس ۱ یا کلاس ۲ برای قسمت متناظر برگشت داده می‌شود. پس از محاسبه مقادیر بتا یا سازگاری برای هر ناحیه مقدار confidence با توجه به فرمول ذکر شده در مقاله محاسبه می‌شود و در متغیر  $cf$  قرار می‌گیرد. حال با استفاده از بتاهای محاسبه شده در هر قسمت بندی برای هر ناحیه کلاس هر ناحیه را با توجه به این مقادیر محاسبه می‌کنیم و در واقع برای آن یک قانون فازی تولید می‌کنیم. روش انجام کار بدین صورت است که ۲ بتای محاسبه شده را یکدیگر مقایسه کرده هر کدام که بیشتر بود کلاس متناظر با آن را برای قسمت مورد نظر انتخاب می‌کنیم. اما اگر برای یک منطقه ی خاص مقادیر بتاها با یکدیگر برابر بودند برای آن منطقه ی خاص هیچ کلاسی انتخاب نمی‌شود و در واقع برای آن منطقه هیچ قانونی تولید نمی‌شود. پس از آنکه با مقایسه مقادیر سازگاری ( $\beta$ ) کلاس یک منطقه مشخص شد و در واقع قانون فازی آن تولید شد، باید مقادیر مربوط به این کلاس شامل ماتریس نواحی، ماتریس تعداد قوانین، ماتریس  $cf$ ها و ماتریس  $K$  به روز شوند.

در این قسمت از کد نوشته شده برای تولید قوانین فازی در محیط متلب می‌توان با خارج کردن دستوراتی که با fprintf شروع می‌شوند از حالت comment تمامی قوانین فازی تولید شده ی متناظر با هر قسمت بندی را به صورت کامل مشاهده کرد. در شکل زیر جهت نمونه برای  $L=3$  قوانین تولید شده که خروجی حاصل از پیاده سازی می باشند نشان داده شده اند.

```
for k = 2 rules are :
if "i" is 1 and "j" is 1 then class is G2 and CF = 0.770477
if "i" is 1 and "j" is 2 then class is G2 and CF = 0.147534
if "i" is 2 and "j" is 1 then class is G2 and CF = 0.541989
if "i" is 2 and "j" is 2 then class is G1 and CF = 0.264731

for k = 3 rules are :
if "i" is 1 and "j" is 1 then class is G2 and CF = 1.000000
if "i" is 1 and "j" is 2 then class is G2 and CF = 0.782518
if "i" is 1 and "j" is 3 then class is G1 and CF = 0.584817
if "i" is 2 and "j" is 1 then class is G2 and CF = 0.965455
if "i" is 2 and "j" is 2 then class is G2 and CF = 0.366138
if "i" is 2 and "j" is 3 then class is G1 and CF = 0.707941
if "i" is 3 and "j" is 1 then class is G2 and CF = 0.972590
if "i" is 3 and "j" is 2 then class is G1 and CF = 0.304309
if "i" is 3 and "j" is 3 then class is G1 and CF = 1.000000
number of generated rules are : 13
```

## Generate Test Data

در این قسمت داده‌های تست ما تولید می‌شوند که برای کلاس بندی آنها از قوانین فازی به دست آماده در مرحله قبل استفاده می‌کنیم. در این قسمت جهت به دست آوردن دقت الگوریتم در پایان کار نیاز به محاسبه کلاس داده‌ها نیز داریم تا در انتها با کلاس‌هایی که بر اساس قوانین فازی به دست می‌آیند مقایسه شوند و دقت را برای ما اندازه‌گیری کنند، از این رو به همان روشی که برای داده‌های آموزش عمل کردیم کلاس هر داده محاسبه می‌شود و در پایان این بخش برداری که شامل کلاس‌ها می‌باشد در متغیر  $t$  قرار می‌گیرد.

## Plot Test Data

در این قسمت نیز مانند قسمت Plot train data ما داده‌های تولید شده در مرحله ی قبل را جهت پیدا کردن دیدی مناسب و درکی بهتر از موضوع در یک فضای ۲ بعدی ترسیم نموده. وجود این بخش اختیاری می‌باشد و تاثیری در پاسخ نهایی ندارد.

## Fuzzy Inference For Test Data Pattern Classification

در این قسمت از پیاده سازی، عمل کلاس بندی داده‌های تست بر اساس قوانین فازی استخراج شده از داده‌های عددی انجام می‌شود. حلقه ی اول به تعداد قوانین کلاس  $G1$  اجرا می‌شود یا به عبارت دیگر به دلیل اینکه هر قانون فازی نوشته شده متناظر با یک بلوک خاص در یک قسمت بندی خاص می‌باشد به ازای تمام بلوک‌هایی که در مرحله ی آموزش از کلاس  $G1$  تشخیص دادیم اجرا می‌شود. در هر تکرار حلقه مقدار  $\alpha_{G1}$  برای تمام داده‌های تست در یک بلوک متناظر با کلاس  $G1$  محاسبه شده و در متغیر  $Z$  قرار داده می‌شود و مقادیر قبلی  $\alpha$  که متناظر با بلوک‌های دیگر کلاس  $G1$  هستند مقایسه می‌شوند و در نهایت ماکسیمم آنها در ماتریس  $\alpha\_g1$  قرار می‌گیرد. حلقه ی دوم نیز تمام مراحل حلقه ی اول را ولی این بار برای کلاس  $G2$  انجام می‌دهد و در انتها مقادیر ماکسیمم  $\alpha_{G2}$  را در ماتریس  $\alpha\_g2$  قرار می‌دهد. در این بخش همانطور که مشاهده می‌شود ۲ فرمول برای محاسبه  $Z$  با یک membership function وجود دارد که اولی مقادیر  $CF$  را برای محاسبه در نظر گرفته ولی در فرمول دوم مقدار  $Z$  بدون در نظر گرفتن  $CF$  محاسبه می‌شود. تفاوت بین این ۲ حالت را در قسمت نتایج مشاهده خواهیم نمود.

در ادامه یک دستور شرطی داریم که ۲ ماتریس  $\alpha\_g1$  و  $\alpha\_g2$  را به یکدیگر مقایسه کرده و برای هر داده ی آموزش اگر مقدار  $\alpha_{G1}$  بیشتر از مقدار  $\alpha_{G2}$  باشد آن داده از کلاس  $G1$  و در غیر این صورت از کلاس  $G2$  خواهد بود. سپس نتیجه ی حاصل از کلاس بندی داده‌های تست به همراه اختلاف مقادیر  $\alpha$  برای هر داده ی آموزش که از آن به عنوان grade of support یاد می‌کنیم در ماتریس results قرار می‌گیرد.

## Rate Computation

در این قسمت دقت کلاس بندی داده‌های تست یا به عبارت دیگر دقت الگوریتم محاسبه می شود. به این صورت که کلاس هایی که برای داده‌های تست به دست آمده اند که در واقع همان ستون اول ماتریس **results** می باشند در ماتریس **u** قرار می گیرند، حال اختلاف بین ماتریس **u** و ماتریس **t** که در قسمت **generate test data** تولید کردیم و شامل کلاس واقعی داده‌های تست می باشد را محاسبه کرده و دقت روش را به دست می آوریم.

## Plot Result

در این قسمت داده‌های تست و کلاسی که برای هر کدام از آنها توسط الگوریتم بدست آمده در یک فضای ۲ بعدی ترسیم می شوند. این قسمت نیز تاثیری در پاسخ نهایی ندارد و جهت مقایسه ی ظاهری داده‌های تست به همراه کلاس واقعی در نمودارهای قبلی و کلاس هایی که توسط الگوریتم به دست آمده اند و به دست آوردن دیدی نسبی و ظاهری از دقت الگوریتم پیاده سازی شده است.

## Membership Functions

در این بخش ۲ **membership function** مثلثی و ذوزنقه ای ارائه شده در مقاله جهت محاسبه ی درجه ی عضویت داده‌ها پیاده سازی شده اند، که هر کدام از آنها ۳ مقدار به عنوان ورودی دریافت می کنند و مقدار درجه عضویت را بر می گردانند. با توجه به فرمول ارائه شده برای این **membership function** ها در مقاله و همانطور که در پیاده سازی مشاهده می شود مقدار خروجی یا به عبارت دیگر همان درجه عضویت در هر ۲ تابع به مقادیر **K** و **i** بستگی دارد لذا در تقسیم بندی‌های مختلف و نواحی متفاوت که مقادیر **K** و **i** مرتباً دچار تغییر می شوند این توابع نیز دائماً دست خوش تغییرات می شوند.



## نتیجه گیری:

تعدادی از نتایج به دست آمده به همراه خروجی حاصل از پیاده سازی نشان داده می شوند و مابقی نتایج بدون خروجی مورد بررسی قرار می گیرند.

در شکل زیر خروجی حاصل از membership function های مثلثی برای ۱۰ تکرار همراه با ۴۰ نمونه ی train و ۱۰۰ داده ی تست برای  $L=20$  در ۲ حالت وجود CF شکل a و عدم وجود CF شکل b برای problem 1 که توسط مقاله تعریف شده نشان داده شده است. همان طور که مشاهده می شود برای حالت

```
rate_per_each_iterations =  
97 94 94 96 96 95 94 95 90 90  
  
total_rate =  
94.1000 a  
  
rate_per_each_iterations =  
92 93 90 88 93 92 83 93 93 86  
  
total_rate =  
90.3000 b
```

وجود پارامتر CF الگوریتم عملکرد بهتری داشته است و با دقت بیشتری داده های تست را کلاس بندی کرده است.

در ۲ تصویر زیر نیز تمام شرایط مانند مرحله ی قبل می باشد جز اینکه در این حالت از ۱۰۰ داده برای آموزش استفاده شده است. مشاهده می شود که مانند حالت قبلی اگر در محاسبات از پارامتر CF استفاده کنیم دقت الگوریتم در کلاس بندی افزایش پیدا می کند (تصویر بالایی). نتیجه ی دیگری که از مقایسه ی این حالت با حالت قبلی گرفته می شود این است که با افزایش تعداد داده های آموزش الگوریتم عمل کرده بهتری داشته و به دقت بهتری دست پیدا کرده است.

```
rate_per_each_iterations =  
95 97 95 95 100 95 95 98 97 97  
  
total_rate =  
96.4000
```

```
rate_per_each_iterations =
```

```
91 89 96 92 95 93 96 91 95 95
```

```
total_rate =
```

```
93.3000
```

با مشاهده ی خروجی در ۲ حالت مختلف استفاده از membership های مثلثی و دوزنقه ای این نتیجه حاصل می شود که شکل تابع مورد استفاده تاثیر چندانی در خروجی ندارد. در حالت توزیع شده، یعنی حالتی که ما در اینجا بررسی کردیم که در آن یک مقدار ماکسیمم ثابت برای  $L$  در نظر گرفته می شود و تا رسیدن  $K$  به آن به ازای مقادیر مختلف  $K$  قسمت بندی را انجام می دهیم، مقدار  $L$  انتخابی تاثیری در نتیجه ی جواب نخواهد داشت. همچنین در حالت های مختلف استفاده از  $t$ -norm ضرب و مینیمم برای محاسبه سازگاری ها مشاهده می شود که  $t$ -norm ضرب منجر به دقت بیشتری برای الگوریتم نسبت به مینیمم می شود.